

Document technique

Explorer des données et modéliser une base de données SQL

4/8/2025

TEIXEIRA Allison

OpenClassrooms

Sommaire

Introduction	2
I. Exploration des données	3
II. Création du dictionnaire des données.....	4
III. Schéma relationnel de la base de données	6
IV. Création et chargement de la base de données.....	7
V. Analyse des données	10
Conclusion	12

Introduction

L'**objectif** de ce projet est de créer une base de données pour une entreprise spécialiste de l'assurance habitation. Cette base de données doit contenir l'ensemble des informations correspondant aux contrats d'assurances possédés par l'entreprise, notamment concernant le type de logement assuré, son adresse, la commune et la région dans lesquelles il se situe, son utilisation, la formule choisie et son tarif mensuel par exemple. Elle doit ainsi leur permettre par la suite de faire une analyse des données plus précise sur le marché des assurances habitation afin de pouvoir mieux accompagner leurs clients.

Ce rapport technique a donc pour objectif de présenter la méthodologie de la création de cette base de données, ainsi que l'analyse des résultats afin de répondre aux objectifs de l'entreprise d'assurances.

Il a donc été structuré de la façon suivante.

Nous commencerons par une 1^{ère} partie expliquant la méthodologie d'exploration des données que j'ai utilisée afin d'identifier les différents types de données présentes dans les fichiers qui serviront à créer la base de données. Puis, la 2^{ème} partie expliquera la méthode de création du dictionnaire des données et comment j'ai choisi les types de données de la future base. Ensuite, la 3^{ème} partie présentera une explication de la construction du schéma relationnel des données, qui permet d'identifier les associations entre les différentes données et ainsi définir comment relier les tables de la base. Dans la 4^{ème} partie, nous verrons comment la base de données finale a été créée dans le Système de Gestion de Base de Données Relationnel (SGBDR), et comment les données ont été chargées dans celle-ci. Enfin, nous terminerons par une dernière partie contenant une analyse des données répondant aux objectifs donnés par l'entreprise d'assurances, avant de finir par la conclusion du projet.

Le **SGBDR** utilisé est le logiciel SQLite Studio. Contrairement à MySQL, SQLite est léger et ne nécessite donc pas l'utilisation d'un serveur externe.

La **base de données** créée est une base de données de type SQLite 3, donc compatible avec le langage SQL (Structured Query Language ou « langage de requêtes structurées »). Son utilisation implique quelques restrictions et particularités par rapport à MySQL, mais cela ne pose pas de problème dans ce projet.

Enfin, les **données** présentes dans les fichiers qui constitueront la base sont de type CSV (Comma-separated values), c'est-à-dire que les données sont de format texte et représentées sous forme de valeurs séparées par des virgules.

I. Exploration des données

Afin de comprendre les différents types de données présentes dans la future base de données, je suis allée consulter les 2 fichiers Excel contenant ces données : « Contrat.csv » et « Region.csv ».

Après ouverture des 2 fichiers, j'ai d'abord noté les titres des colonnes présentes, puis j'ai cherché à comprendre ce qu'elles décrivaient. Par exemple : les données de la colonne « Formule » du fichier « Contrat » correspondent au type de formule qui a été choisi pour assurer le logement concerné dans cette ligne.

Chaque ligne correspond à un objet et chaque colonne est une caractéristique de cet objet.

Dans le fichier « Contrat », chaque ligne correspond à un contrat souscrit pour assurer un logement. Chaque contrat a un numéro d'identification unique (Contrat_ID, **clé primaire**) qui correspond ensuite à un seul logement, caractérisé lui-même par son adresse (comprenant les numéro et type de voie, le nom de la voie, le code postal et le nom de la commune où se situe le logement, et éventuellement un indice de répétition de l'adresse si plusieurs logements ont la même adresse). Ensuite, lui est associé sa surface, son type (Appartement ou Maison) et le statut de son occupant (Locataire ou Propriétaire) et enfin, le type d'assurance utilisée pour assurer ce logement (comprenant le type d'utilisation du logement (Résidence ou location), la formule choisie (Integral ou Classique) et la valeur des biens présents dans le logement à assurer également) ainsi que le prix de la cotisation mensuelle prélevée au client pour cette assurance.

En ce qui concerne le fichier « Region », chaque ligne correspond à une commune unique, caractérisée par son nom et son code, puis associée à la région (numéro et nom), l'académie (nom) et le département (numéro et nom) dans lesquels elle se situe. Ensuite, lui est associé un identifiant unique, constitué d'une concaténation du code de la commune et de celui du département où elle se situe (Code_dep_code_commune, **clé primaire**), qui sera également utilisé dans le fichier « Contrat » afin de lier les 2 tables pour pouvoir associer chaque contrat unique aux informations de la commune où il se situe (**clé étrangère**).

Ensuite, pour pouvoir identifier le type de données, j'ai commencé par regarder dans chaque colonne des 2 fichiers s'il s'agissait de données numériques ou des chaînes de caractères, et vérifié si elles contenaient ou non des valeurs nulles (cases vides) afin d'ajouter une contrainte **NOT NULL** si besoin. La contrainte NOT NULL implique que la caractéristique doit absolument avoir de valeur, elle ne peut pas être « vide ».

Pour les données de type numérique, j'ai regardé si c'était des nombres entiers (**INTEGER**, sans virgule) ou décimaux (**DECIMAL**, avec des chiffres après la virgule), et si ils avaient une contrainte de longueur afin de l'ajouter au dictionnaire si nécessaire (le code postal est un nombre entier à 4 chiffres par exemple).

Enfin, pour les données de type chaîne de caractères, j'ai commencé par regarder si elles avaient une longueur définie ou pas (**CHAR** pour une longueur fixe, **VARCHAR** pour une longueur non fixe mais limitée, et **TEXT** pour une chaîne de caractère a longueur illimitée) afin d'ajouter la contrainte de longueur dans le dictionnaire si nécessaire. Et pour terminer, j'ai appliqué une fonction de filtration sur ces colonnes, afin de vérifier s'il pouvait

s'agir de données booléennes ou non (**BOOLEAN**, il n'existe que 2 valeurs fixes pour ces données et qui représentent un choix unique).

Je n'ai pas trouvé de données de type **DATE**.

II. Création du dictionnaire des données

	Nom des colonnes	Type de données	Taille	Clé	Description
CONTRAT.CSV	Contrat_ID	INT		Clé primaire	Id unique pour les contrats
	No_voie	INT			Numéro dans la voie pour l'adresse du logement assuré
	B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
	Type_de_voie	VARCHAR	3		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
	Voie	TEXT			Libellé de la voie pour l'adresse du logement assuré
	Code_dep_code_commune	INT		Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique
	Code_postal	INT			Code postal pour l'adresse du logement assuré
	Surface	INT			Taille du logement assuré
	Type_local	BOOLEAN			Type de logement assuré (Appartement ou Maison)
	Occupation	BOOLEAN			Statut de l'occupant du logement assuré (Locataire ou Propriétaire)
	Type_contrat	TEXT			Type d'utilisation du logement assuré (Résidence ou location)
	Formule	BOOLEAN			Type de formule d'assurance choisie pour le logement (Integral ou Classique)
	Valeur_declaree_biens	TEXT			Fourchette représentant la valeur des biens importants présents dans le logement assuré
REGION.CSV	Prix_cotisation_mensuel	INT			Prix de la cotisation mensuelle à payer par le client pour assurer le logement
	Code_dep_code_commune	INT		Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
	reg_code	INT			Numéro de code de la région
	reg_nom	TEXT			Nom de la région
	aca_nom	TEXT			Nom de l'académie régionale
	dep_nom	TEXT			Nom du département
	com_nom_maj_court	TEXT			Nom de la commune
	dep_code	VARCHAR	3		Numéro de code du département
	dep_nom_num	TEXT			Concaténation du nom du département et de son numéro de code

Capture d'écran du dictionnaire des données pour la base de données des assurances.

Le dictionnaire des données correspond au **Modèle Conceptuel des Données** (MCD) de la création de la base de données. Il permet de visualiser les concepts présents dans la base de données (contrats, logements, adresses, assurances, départements, communes, etc.) et les associations qui peuvent exister entre ceux-ci.

Pour la table « Contrat » :

- En ce qui concerne les colonnes « Contrat_ID », « No_voie », « Code_dep_code_commune », « Code_postal », « Surface » et « Prix_cotisation_mensuel », ce sont des nombres entiers. J'ai donc décidé de mettre un type **INTEGER** (INT) sans contrainte de taille, car ces valeurs ne peuvent pas contenir de nombre à virgule et leur taille, bien qu'étant petite, doit rester variable afin de pouvoir s'adapter librement à la caractéristique.
- Pour la colonne « B_T_Q », elle concerne un indicateur de répétition de l'adresse du logement de type chiffre ou lettre de l'alphabet. C'est donc soit un chiffre unique, soit une chaîne de caractères de valeur fixe ne contenant qu'1 seule lettre. J'ai donc choisi un type **CHARACTER** (CHAR) avec une contrainte de taille 1.
- La colonne « Type_de_voie » contient des données indiquant le type de voie où se situe le logement comme « avenue » ou « route » abrégé (AV, Rte...). Ce sont des chaînes de caractères de longueur


variable, mais d'une taille maximum de 3 lettres. J'ai donc décidé de mettre un type **CHARACTER VARYING** (VARCHAR) avec une contrainte de taille 3.

- Pour les colonnes « Voie » et « Type_contrat », elles contiennent des chaînes de caractères longues, dont la longueur variable et limitée. J'ai donc choisi un type **TEXT** sans contrainte de longueur.
- La colonne « Valeur_declaree_biens », bien que ce soit des valeurs numériques, elle contient également des caractères spéciaux de type tiret. Nous ne pouvons donc pas les considérées comme des types numériques (INT ou DEC). J'ai donc choisi un type **TEXT** sans contrainte de longueur car la fourchette de valeur déclarée n'est pas limitée.
- Enfin, pour les colonnes « Type_local », « Occupation » et « Formule », elles correspondent à des chaînes de caractères sans limite de taille, mais dont le choix ne peut se faire qu'entre 2 valeurs. Si la 1^{ère} valeur n'est pas vraie alors la 2^{nde} valeur s'applique. J'ai donc ici choisi un type **BOOLEAN**.

Pour la table « Region » :

- Cette table contient en majorité des valeurs correspondant à des chaînes de caractères, sauf pour les colonnes « Code_dep_code_commune » et « reg_code » qui correspondent à des nombres entiers sans limite de taille. C'est pour cela que, pour ces 2 caractéristiques, j'ai choisi un type **INTEGER** (INT) sans contrainte de taille.
- La colonne « dep_code » est particulière car, bien que nous nous attendions à des valeurs numériques de type nombre entier de longueur maximum de 3 chiffres, il existe également 2 départements dont le code contient aussi 1 lettre (2A et 2B). J'ai donc choisi un type **CHARACTER VARYING** (VARCHAR) avec une contrainte de taille 3.
- En ce qui concerne la colonne « dep_nom_num », elle correspond à la concaténation du nom de la commune avec le numéro du département où elle se situe. Elle contient donc à la fois des chaînes de caractères de longueur variable non limitée et des valeurs numériques de type nombre entier. J'ai donc choisi de mettre un type **TEXT**.
- Enfin, pour toutes les autres colonnes : « reg_nom », « aca_nom », « dep_nom », « com_nom_maj_court », elles correspondent toutes à des chaînes de caractères de longueur variable et non limitée. J'ai donc choisi également un type **TEXT** pour ces caractéristiques.

III. Schéma relationnel de la base de données



Capture d'écran du schéma relationnel de la base de données (modélisation UML).

Ce schéma relationnel est un **diagramme de classes**, ou modélisation UML (Langage de Modélisation Unifié). C'est un modèle relationnel. Il correspond au **Modèle Logique des Données** (MLD) de la création de la base de données, et permet de **structurer** les données, notamment en transformant les associations en clés étrangères.

Pour créer ce schéma, j'ai utilisé le logiciel SQL Power Architect.

Dans ce modèle, les tables de la base de données, « Contrat » et « Region », sont présentées sous forme de tableau contenant 3 parties (de haut en bas) :

- Le nom de la table.
- Sa clé primaire (PK, qui permet d'identifier de façon unique chaque objet contenu dans la table), associée à son type.
- Les attributs (caractéristiques) contenus dans la table et leurs types, associés à une contrainte de taille ou non entre parenthèses, ainsi que la clé étrangère (FK, qui permet d'associer les 2 tables entre-elles en intégrant la clé primaire d'une table dans la 2^{ème}).

Pour compléter le type de chaque attribut, la mention **NOT NULL** a été ajoutée si la valeur demandée ne peut pas être nulle (case vide).


Dans ce schéma, la **multiplicité** entre les 2 tables est de **un à plusieurs** (1..*). La table « Region » correspond au côté « **un** ». En effet, un contrat d'assurance ne peut correspondre à un logement que dans une seule commune. En revanche, une commune peut posséder plusieurs contrats d'assurance. La table « Contrat » correspond donc au côté « **plusieurs** ».

La clé étrangère doit être placée dans la table qui correspond au côté « plusieurs », elle sera donc dans la table « Contrat ».

IV. Création et chargement de la base de données

La création de la base de donnée physique correspond au **modèle physique de données** (MPD) et consiste à traduire le MLD en **code SQL** afin de créer la base de données et ses tables dans un **Système de Gestion de Base de Données Relationnel** (SGBDR). Dans notre cas, j'ai choisi d'utiliser le logiciel SQLite Studio.

J'ai donc commencé par créer la base de données grâce à la fonction « Ajouter une base de données » incluse dans le logiciel. J'ai choisi une base de données de type SQLite 3 afin qu'elle soit compatible avec le code généré par le logiciel de création du schéma relationnel précédent, SQL Power Architect. Ensuite, j'ai créé une nouvelle base de données et lui ai associé un nom et un chemin d'accès.



Afin de créer les 2 tables, j'ai utilisé le code suivant, généré par le logiciel SQL Power Architect directement à partir du schéma relationnel :

```
CREATE TABLE Region (
    Code_dep_code_commune INT NOT NULL,
    reg_code INT NOT NULL,
    reg_nom TEXT NOT NULL,
    aca_nom TEXT NOT NULL,
    dep_nom TEXT NOT NULL,
    com_nom_maj_court TEXT NOT NULL,
    dep_code VARCHAR(3) NOT NULL,
    dep_nom_num TEXT NOT NULL,
    PRIMARY KEY (Code_dep_code_commune)
);

CREATE TABLE Contrat (
    Contrat_ID INT NOT NULL,
    No_voie INT,
    B_T_Q CHAR(1),
    Type_de_voie VARCHAR(3),
    Voie TEXT NOT NULL,
    Code_dep_code_commune INT NOT NULL,
    Code_postal INT NOT NULL,
    Surface INT NOT NULL,
    Type_local BOOLEAN NOT NULL,
    Occupation BOOLEAN NOT NULL,
    Type_contrat TEXT NOT NULL,
    Formule BOOLEAN NOT NULL,
    Valeur_declaree_biens TEXT NOT NULL,
    Prix_cotisation_mensuel INT NOT NULL,
    PRIMARY KEY (Contrat_ID)
);
```

Capture d'écran du code utilisé pour créer les tables dans la base de données.

Enfin, pour charger les différentes tables, j'ai utilisé la fonction « Importer les données d'une table », incluse également dans le logiciel et accessible en ouvrant la table.

Il suffit ensuite de sélectionner le type de source dans laquelle sont stockées les données, dans notre cas un fichier CSV, puis d'indiquer le chemin d'accès au fichier, ainsi que le fait que la première ligne du fichier correspond aux noms des colonnes si c'est le cas.

← Import données

Source de données à importer de

Type de données source
CSV

Options

Fichier : ir/Documents/Formation_data_analyst/Projets/Projet_3/datas/Region+(7).csv

Texte codé : System

☐ Ignorer les erreurs

Options de source de données

☒ La première ligne représente les noms de colonnes CSV

Cancel Finish

Voici enfin le résultat de la base de données chargée :

SQLiteStudio (3.4.17) - [Region (BDD_assurances_habitation)]

Base de données Structure Affichage Outils Aide

Base de données

Table

	Code_dep_c	reg_code	reg_nom	aca_nom	dep_nom	com_nom_maj_court	dep_code	dep_nom_n
1	1001	84	Auvergne-Rhône-Alpes	Lyon	Ain	L ABERGEMENT CLEMENCIAT	1	Ain (01)
2	1002	84	Auvergne-Rhône-Alpes	Lyon	Ain	L ABERGEMENT DE VAREY	1	Ain (01)
3	1003	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMAREINS	1	Ain (01)
4	1004	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBERIEU EN BUGEY	1	Ain (01)
5	1005	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBERIEUX EN DOMBES	1	Ain (01)
6	1006	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBLEON	1	Ain (01)
7	1007	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBRONAY	1	Ain (01)
8	1008	84	Auvergne-Rhône-Alpes	Lyon	Ain	AMBUTRIX	1	Ain (01)
9	1009	84	Auvergne-Rhône-Alpes	Lyon	Ain	ANDERT ET CONDON	1	Ain (01)
10	1010	84	Auvergne-Rhône-Alpes	Lyon	Ain	ANGLEFORT	1	Ain (01)
11	1011	84	Auvergne-Rhône-Alpes	Lyon	Ain	APREMONT	1	Ain (01)
12	1012	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARANC	1	Ain (01)
13	1013	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARANDAS	1	Ain (01)
14	1014	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBENT	1	Ain (01)
15	1015	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBIGNIEU	1	Ain (01)
16	1016	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARBIGNY	1	Ain (01)
17	1017	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARGIS	1	Ain (01)
18	1018	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARLOD	1	Ain (01)
19	1019	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARMIX	1	Ain (01)
20	1020	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARNANS	1	Ain (01)
21	1021	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARS SUR FORMANS	1	Ain (01)
22	1022	84	Auvergne-Rhône-Alpes	Lyon	Ain	ARTEMARE	1	Ain (01)
23	1023	84	Auvergne-Rhône-Alpes	Lyon	Ain	ASNIERES SUR SAONE	1	Ain (01)
24	1024	84	Auvergne-Rhône-Alpes	Lyon	Ain	ATTIGNAT	1	Ain (01)
25	1025	84	Auvergne-Rhône-Alpes	Lyon	Ain	BAGE LA VILLE	1	Ain (01)

Barre d'état

[10:50:08] Données importées dans le tableau 'Contrat' avec succès. Nombre de lignes importées : 30335

[10:54:03] Données importées dans le tableau 'Region' avec succès. Nombre de lignes importées : 38916

Éditeur SQL 1 Contrat (BDD_assurances_habitation) Region (BDD_assurances_habitation)

Capture d'écran de la base de données créée et chargée.

Dans cet exemple, nous pouvons voir que chaque ligne correspond bien à un **objet** décrivant une commune et ses caractéristiques (nom, codes et noms des département et région où elle se situe, et nom de l'académie à laquelle elle appartient). Chaque commune possède un **identifiant unique** (Code_dep_code_commune) constitué d'un assemblage (concaténation) de son code et du code du département où elle se situe.

Par exemple : la ligne 1 de la table décrit la commune de L'ABERGEMENT CLEMENCIAT, qui se situe dans le département de l'AIN (code : 1), dans la région AUVERGNE-RHONE-ALPES (code : 84), et appartenant à l'académie de LYON. Son identifiant unique est le 1001.

Cet identifiant unique permet donc de constituer la **clé primaire** de la table « Region » car il ne peut correspondre qu'à une seule commune et permet ainsi de l'identifier de façon précise. Enfin, cette clé primaire pourra ensuite être ajoutée comme **clé étrangère** dans la table « Contrat » afin de les relier.

Dans la table « Contrat », chaque ligne correspond à un **objet** décrivant un contrat et ses caractéristiques (adresse, surface, type de logement et type d'occupation et d'utilisation, formule du contrat et son prix mensuel). Chaque contrat possède un identifiant unique (Contrat_ID) spécifique à lui-même.

Par exemple : la ligne 1 de la table décrit le contrat n°100601. Il correspond à un APPARTEMENT de 50m², utilisé comme RESIDENCE PRINCIPALE et occupé par un LOCATAIRE. Il se situe au 190 A RUE CENTRALE, dans la commune dont le code postal est 1370. La formule d'assurance choisie est INTEGRAL, comprenant jusqu'à 25000 € de biens déclarés, et dont le tarif mensuel est de 25 €.

L'identifiant du contrat étant unique, il permet de constituer la **clé primaire** de la table « Contrat » car il ne peut correspondre à un seul contrat et permet ainsi de l'identifier de façon précise.

La **clé étrangère** de cette table correspond à la clé primaire de la table « Region », c'est-à-dire l'identifiant de la commune (Code_dep_code_commune). Elle a été choisie ainsi car elle permet de relier les 2 tables de façon unique. Ainsi un contrat ne pourra être relié qu'à une seule commune (celle dans laquelle il se situe), via son identifiant unique, ainsi qu'à toutes les informations reliées à celle-ci. A l'inverse, une commune pourra être reliée à plusieurs contrats, c'est pourquoi nous ne pouvons pas ajouter la clé étrangère à cette table, car dans ce sens, chaque liaison ne peut pas être unique.

V. Analyse des données

Après avoir effectué les requêtes demandées, j'ai choisi de faire une 1^{ère} analyse sur les résultats suivants afin de répondre à l'objectif de l'entreprise d'assurances, qui est de faire une étude de marché des assurances habitation afin de pouvoir mieux accompagner leurs clients.

Dans ce tableau, nous pouvons voir que les 2 régions possédant le plus grand nombre de contrats, Ile-de-France et Auvergne-Rhône-Alpes, correspondent aux 2 régions ayant également le plus grand nombre d'habitants en France (*source Insee.fr*). Les régions suivantes (possédant plus de 1000 contrats), font également partie du classement des 10 régions les plus peuplées de France (*source Insee.fr*). Les DOM-TOM, quant à eux (Guyane, La Réunion et Martinique), représentent les régions ayant le moins de contrats, mais également les moins peuplées (*source Insee.fr*).

Tableau représentant le nombre de contrats d'assurances souscrits dans chaque région de France possédant au moins une agence de l'entreprise.

req nom	Nombre de contrats
Auvergne-Rhône-Alpes	3042
Bourgogne-Franche-Comté	293
Bretagne	947
Centre-Val de Loire	598
Corse	247
Grand Est	769
Guyane	37
Hauts-de-France	1189
Ile-de-France	14177
La Réunion	8
Martinique	73
Normandie	824
Nouvelle-Aquitaine	2038
Occitanie	1609
Pays de la Loire	1196
Provence-Alpes-Côte d'Azur	3279

com nom mai court	Nombre de contrats
PARIS 18	515
PARIS 17	468
PARIS 15	407
PARIS 16	394
NICE	387
PARIS 11	381
PARIS 20	302
BORDEAUX	302
NANTES	291
PARIS 19	266
PARIS 10	263
PARIS 12	252
PARIS 14	222
GRENOBLE	220
PARIS 9	204
TOULOUSE	187
TOULON	170
COURBEVOIE	163
LILLE	161
PARIS 3	159

Si nous regardons maintenant plus en détail la liste des communes ayant au moins 150 contrats, nous pouvons constater que la ville de Paris, située dans la région Ile-de-France, ainsi que ses arrondissements, est la plus représentée. Ceci semble logique lorsque l'on prend en considération le nombre d'habitants au m² et la surface élevées de la capitale française.

Tableau représentant le nombre de contrats d'assurances souscrits dans chaque ville possédant au moins 150 contrats, et où se situe au moins une agence de l'entreprise.

Le prix moyen de la cotisation mensuelle des contrats souscrits dans l'entreprise, toutes régions et toutes formules confondues, est de 19,33 €. Il est un peu plus élevé que la moyenne relevée nationale, qui s'élève à 17,20 € (*source lesfurets.com*).

Prix moyen cotisation mensuelle
19.33

Si on prend en considération cette moyenne, seuls 3 départements proposent des prestations dont la moyenne mensuelle la dépasse, c'est-à-dire Paris, les Hauts-de-Seine et le Val-de-Marne. Ces 3 départements appartiennent à nouveau à la région Ile-de-France, et Paris correspond également au département le plus cher avec une moyenne mensuelle de 36,40 € pour ses contrats souscrits.

Tableau représentant la liste des 10 départements dont le prix moyen de la cotisation mensuelle est le plus élevé.

dep nom	Prix moyen cotisation mensuelle
Paris	36.4
Hauts-de-Seine	26.27
Val-de-Marne	19.82
Yvelines	18.89
Rhône	18.49
Ain	18.24
Alpes-Maritimes	18.14
Charente-Maritime	17.32
Haute-Savoie	17.15
Corse-du-Sud	17.07

Enfin, en étudiant le nombre de contrats souscrits en fonction de la catégorie de prix de la valeur déclarée des biens présents dans le logement, nous pouvons voir que la majorité des contrats souscrits sont associés à une valeur déclarée inférieure à 25 000€ (22 720 contrats). La catégorie suivante est également bien représentée avec 6 815 contrats souscrits pour une valeur de biens entre 25 000 et 50 000 €. Enfin, les catégories de valeur déclarées des biens supérieures à 50 000 € sont très peu représentées en comparaison aux autres.

Valeur declaree biens	Nombre de contrat:
0-25000	22720
100000+	104
25000-50000	6815
50000-100000	696

Tableau représentant le nombre de contrats souscrits en fonction de la catégorie de valeur déclarée pour les biens présents dans le logement assuré, toutes régions confondues et toutes formules confondues.

Il pourrait donc sembler judicieux d'améliorer les formules déjà existantes en incluant dans celles-ci l'assurance des biens contenus dans le logement pour une valeur allant jusqu'à 50 000 €, puis d'appliquer un tarif supplémentaire à barème dégressif pour les valeurs déclarées plus élevées.

Conclusion

En conclusion, pour effectuer l'étude de marché, je conseille donc à l'entreprise de se concentrer, dans un 1^{er} temps, sur l'analyse des données des régions Ile-de-France et Auvergne-Rhône-Alpes, qui représentent les 2 régions les plus peuplées et ayant le plus de contrats d'assurance dans l'entreprise, mais qui correspondent également au prix moyen d'assurance habitation les plus élevés de France (*source LeLynx.fr*). Ensuite, ils pourront effectuer une comparaison de ces données avec celles des régions Nouvelle-Aquitaine et Occitanie, qui représentent 2 régions ayant également l'un des plus grands nombre de contrats souscrits dans l'entreprise, mais aussi les 2 régions les plus peuplées de France après l'Ile-de-France et Auvergne-Rhône-Alpes (*source Insee.fr*), mais surtout 2 des régions les moins chères en terme d'assurance habitation (*source LeLynx.fr*).

Ensuite, en fonction des résultats de cette comparaison, peut-être qu'ils pourront trouver des axes d'amélioration afin de mieux adapter les formules d'assurance proposées à leurs clients, notamment en fonction de la région dans laquelle se situe le logement, son ancienneté, et le pouvoir d'achat des habitants de cette région.

Par exemple, il pourrait être possible d'intégrer l'assurance des biens contenus dans le logement à hauteur de 50 000 € dans les 2 formules, tout en essayant de rester à un prix moyen mensuel de cotisation autour de 18 €, ce qui représenterait une augmentation mensuelle de 1 € seulement.

Enfin, afin d'améliorer la base de données et ainsi effectuer des analyses plus précises, je suggère d'ajouter dans la base l'ancienneté du logement (sa date de construction ou de dernière rénovation), afin de pouvoir prendre en compte l'état de vétusté du logement et ainsi adapter l'assurance en conséquences. Mais également, le statut de l'occupant (Etudiant, Salarié ou Sans emploi), afin de pouvoir prendre en compte sa capacité de paiement et ainsi ajouter un garant si besoin. Ou encore une précision sur la localisation du logement, proche d'une zone inondable par exemple, afin de pouvoir adapter la formule à un risque de catastrophe naturelle si nécessaire.