

Explorer des données et modéliser une base de données SQL



**PRÉSENTATION DE LA MÉTHODOLOGIE ET
ANALYSE DES DONNÉES.**

Sommaire

2

Introduction

- I. Exploration des données
- II. Création du dictionnaire des données
- III. Schéma relationnel de la base de données
- IV. Création et chargement de la base de données
- V. Analyse des données



Conclusion

Introduction

3

Objectif du projet :

Créer une BDD* pour une entreprise spécialiste de l'assurance habitation

=> contenant les informations concernant les contrats possédés par l'entreprise (type de logement, adresse, commune et région, utilisation, formule et tarif).

=> afin de leur permettre de faire une analyse du marché des assurances habitations pour pouvoir mieux accompagner leurs clients.

Objectif de la présentation :

Présenter la méthodologie de création de la BDD et l'analyse des résultats répondants aux objectifs de l'entreprise.

SGBDR* utilisé

- **SQLite Studio**
- Léger et ne nécessite pas l'utilisation d'un serveur externe.

BDD utilisée

- **type SQLite 3**
- Compatible avec le langage SQL*.
- Implique des restrictions et particularités mais cela ne présente pas de problème pour le projet.

Données

- **type CSV***
- Format texte et représentées sous forme de valeurs séparées par des virgules.

*BDD = Base De Données

SGBDR = Système de Gestion de Base de Données Relationnelle

*SQL = Structured Query Language
CSV = Comma-Separated Values

I. Exploration des données

4

I.

Consultation
des fichiers
Excel
contenant les
données



II.

Identification
des titres des
colonnes et de
ce que décrit
chaque donnée



III.

Description des
données

1 ligne = 1 objet
1 colonne = 1
caractéristique de
l'objet

- 1 ligne = 1 contrat souscrit pour un logement, caractérisé par :
- son numéro d'identifiant unique (**clé primaire**)
- l'adresse du logement (n°, type et nom de la voie, code postal et nom de la commune, indice de répétition de l'adresse)
- sa surface, son type et le statut de l'occupant
- le type d'assurance choisie selon l'utilisation du logement, sa formule et son tarif mensuel

Contrat.csv



- 1 ligne = 1 commune, caractérisée par :
- Son nom et son code
- Sa région (n° et nom)
- L'académie à laquelle elle appartient
- Son département (n° et nom)
- Son identifiant unique (clé primaire) : concaténation du code de la commune et du code du département associé

Region.csv



Exemple : colonne « Formule » du fichier
« Contrat » = type de formule choisie pour
assurer le logement concerné.

I. Exploration des données

5

VI.

Identification du
type des données

Numériques

- Nombres entiers (INT), sans virgule
- Nombre décimal (DEC), avec virgule
- Contrainte de longueur ou non

Chaînes de
caractères

- Longueur fixe (CHAR)
- Longueur non fixe mais limitée (VARCHAR)
- Longueur non limitée (TEXT)
- Type Booléen (BOOLEAN) = choix entre 2 valeurs uniquement

Valeurs
nulles

- Ajouter la contrainte NOT NULL si nécessaire

**INT = Integer*
DEC = decimal
CHAR = character
VARCHAR = character varying

II. Création du dictionnaire des données

6


	Nom des colonnes	Type de données	Taille	Clé	Description
CONTRAT.CSV	Contrat_ID	INT		Clé primaire	Id unique pour les contrats
	No_voie	INT			Numéro dans la voie pour l'adresse du logement assuré
	B_T_Q	CHAR	1		Indicateur éventuel de répétition pour l'adresse du logement assuré sur un caractère
	Type_de_voie	VARCHAR	3		Type de voie pour l'adresse du logement assuré: rue, av (Avenue), rte (Route), ...
	Voie	TEXT			Libellé de la voie pour l'adresse du logement assuré
	Code_dep_code_commune	INT		Clé secondaire	Concaténation du code département et code commune pour avoir une clé unique
	Code_postal	INT			Code postal pour l'adresse du logement assuré
	Surface	INT			Taille du logement assuré
	Type_local	BOOLEAN			Type de logement assuré (Appartement ou Maison)
	Occupation	BOOLEAN			Statut de l'occupant du logement assuré (Locataire ou Propriétaire)
	Type_contrat	TEXT			Type d'utilisation du logement assuré (Résidence ou location)
	Formule	BOOLEAN			Type de formule d'assurance choisie pour le logement (Integral ou Classique)
REGION.CSV	Valeur_declaree_biens	TEXT			Fourchette représentant la valeur des biens importants présents dans le logement assuré
	Prix_cotisation_mensuel	INT			Prix de la cotisation mensuelle à payer par le client pour assurer le logement
	Code_dep_code_commune	INT		Clé primaire	Concaténation du code département et code commune pour avoir une clé unique
	reg_code	INT			Numéro de code de la région
	reg_nom	TEXT			Nom de la région
	aca_nom	TEXT			Nom de l'académie régionale
	dep_nom	TEXT			Nom du département
	com_nom_maj_court	TEXT			Nom de la commune
	dep_code	VARCHAR	3		Numéro de code du département
	dep_nom_num	TEXT			Concaténation du nom du département et de son numéro de code

MCD = **Modèle Conceptuel des données**, permet de visualiser les concepts présents dans la BDD (contrats, logement, adresses, régions, communes, etc.) et les associations qui peuvent exister entre eux.

- ⇒ Attribution des types et contraintes à chaque donnée en fonction de l'identification faite à l'étape précédente.
- ⇒ Clé primaire attribuée à une caractéristique permettant d'identifier de façon unique et spécifique chaque objet de la table.
- ⇒ Clé secondaire (ou étrangère) = clé primaire de la table « plusieurs » insérée dans la table « 1 », permet de relier les 2 tables.

III. Schéma relationnel de la base de données

7



MLD = **Modèle Logique des données**, permet de structurer les données en transformant les associations en clés étrangères.

- Modèle utilisé = **diagramme de classes** (ou modélisation UML) => modèle relationnel
- **1 table** (fichier contenant les données) = 1 tableau composé de 3 parties (de haut en bas) :
 - le nom de la table
 - Sa clé primaire (PK) et son type : permet d'identifier chaque objet contenu dans la table de façon unique
 - Les attributs contenus dans la table (caractéristiques), associés à leur type, une contrainte de taille et la mention NOT NULL si nécessaire, ainsi que l'identification de la clé étrangère (FK) permettant d'associer les 2 tables.
- **Multiplicité** = 1 à plusieurs (1..*) :
 - Coté « 1 » = table « Région » => 1 contrat ne peut correspondre qu'à un seul logement situé dans une seule commune.
 - Coté « plusieurs » = table « Contrat » => 1 commune peut posséder plusieurs contrats pour différents logements.

Clé étrangère = placée dans la table côté « plusieurs », correspond à l'intégration de la clé primaire de la table « 1 » dans la 2^{ème}.

IV. Création et chargement de la base de données

8

MPD = **Modèle Physique des données**, consiste à traduire le MLD (schéma relationnel) en code SQL afin de créer la base de données et ses tables dans un SGBDR.

Chargement des données des 2 tables

=> fonction « Importer les données d'une table » + type de source CSV


Création d'une BDD de type SQLite 3

=> compatible avec le code généré à partir du schéma relationnel

Création des 2 tables à partir du code suivant :

```
CREATE TABLE Region (  
  Code_dep_code_commune INT NOT NULL,  
  reg_code INT NOT NULL,  
  reg_nom TEXT NOT NULL,  
  aca_nom TEXT NOT NULL,  
  dep_nom TEXT NOT NULL,  
  com_nom_maj_court TEXT NOT NULL,  
  dep_code VARCHAR(3) NOT NULL,  
  dep_nom_num TEXT NOT NULL,  
  PRIMARY KEY (Code_dep_code_commune)  
);
```

```
CREATE TABLE Contrat (  
  Contrat_ID INT NOT NULL,  
  No_voie INT,  
  B_T_Q CHAR(1),  
  Type_de_voie VARCHAR(3),  
  Voie TEXT NOT NULL,  
  Code_dep_code_commune INT NOT NULL,  
  Code_postal INT NOT NULL,  
  Surface INT NOT NULL,  
  Type_local BOOLEAN NOT NULL,  
  Occupation BOOLEAN NOT NULL,  
  Type_contrat TEXT NOT NULL,  
  Formule BOOLEAN NOT NULL,  
  Valeur_declaree_biens TEXT NOT NULL,  
  Prix_cotisation_mensuel INT NOT NULL,  
  PRIMARY KEY (Contrat_ID)  
);
```



V. Analyse de données

9

Requêtes utilisées

```
SELECT reg_nom, COUNT(Contrat_ID) as Nombre_de_contrats
FROM Region
```

```
JOIN Contrat ON Contrat.Code_dep_code_commune =
Region.Code_dep_code_commune
```

```
GROUP BY reg_nom
```

```
SELECT com_nom_maj_court, COUNT(Contrat_ID) as Nombre_de_contrats
FROM Region
```

```
JOIN Contrat ON Contrat.Code_dep_code_commune =
Region.Code_dep_code_commune
```

```
GROUP BY com_nom_maj_court
```

```
HAVING COUNT(Contrat_ID) >= 150
```

```
ORDER BY COUNT(Contrat_ID) DESC
```

Objectifs

Comptabiliser le nombre de contrats possédés par l'entreprise, en fonction des régions ou des communes.

Formules

SELECT = extrait les valeurs demandées.

COUNT = compte le nombre de valeurs.

GROUP BY = agrège les valeurs en fonction d'une caractéristique.

HAVING = ajoute une contrainte.

ORDER BY + DESC = classe les valeurs de façon décroissante.

Résultats

= nombre de contrats possédés par l'entreprise dans chaque région (1),
et pour chaque commune possédant plus de 150 contrats, ordonné es de façon décroissante (2).

Analyse

- Les 2 régions possédant le plus grand nombre de contrats correspondent également aux 2 régions les plus peuplées de France (*source Insee.fr*).
- Les régions suivantes (> 1000 contrats) font également partie du top 10.
- Les DOM-TOM possèdent le moins de contrats mais sont également les régions les moins peuplées.
- Paris et ses arrondissements, situés dans la région Ile-de-France, représentent également la commune possédant le plus grand nombre de contrat.
⇒ Logique si nous prenons en considération le nombre d'habitants au m² et la surface élevés de la capitale française.

reg_nom	Nombre de contrat:
Auvergne-Rhône-Alpes	3042
Bourgogne-Franche-Comté	293
Bretagne	947
Centre-Val de Loire	598
Corse	247
Grand Est	769
Guyane	37
Hauts-de-France	1189
Ile-de-France	14177
La Réunion	8
Martinique	73
Normandie	824
Nouvelle-Aquitaine	2038
Occitanie	1609
Pays de la Loire	1196
Provence-Alpes-Côte d'Azur	3279

Nombre de contrats
souscrits par région.

com_nom_maj_court	Nombre de contrat:
PARIS 18	515
PARIS 17	468
PARIS 15	407
PARIS 16	394
NICE	387
PARIS 11	381
PARIS 20	302
BORDEAUX	302
NANTES	291
PARIS 19	266
PARIS 10	263
PARIS 12	252
PARIS 14	222
GRENOBLE	220
PARIS 9	204
TOULOUSE	187
TOULON	170
COURBEVOIE	163
LILLE	161
PARIS 3	159

Liste des communes
possédant plus de 150
contrats.

V. Analyse de données

10

Requêtes utilisées

```
SELECT ROUND (AVG(Prix_cotisation_mensuel), 2) as  
Prix_moyen_cotisation_mensuelle  
FROM Contrat
```

```
SELECT dep_nom, ROUND (AVG(Prix_cotisation_mensuel), 2) as  
Prix_moyen_cotisation_mensuelle
```

```
FROM Region
```

```
JOIN Contrat ON Contrat.Code_dep_code_commune =  
Region.Code_dep_code_commune
```

```
GROUP BY dep_nom
```

```
ORDER BY AVG(Prix_cotisation_mensuel) DESC limit 10
```

```
SELECT Valeur_declaree_biens, COUNT(Contrat_ID) as  
Nombre_de_contrats
```

```
FROM Contrat
```

```
GROUP BY Valeur_declaree_biens
```

Objectifs

Calculer le prix moyen de la cotisation mensuelle de tout les contrats possédés par l'entreprise, puis des 10 départements dont le prix est le plus élevé.

Comptabiliser le nombre de contrats possédés en fonction de la valeur déclarée des biens du logement.

Formules

ROUND + 2 = arrondi la valeur à 2 décimales.

AVG = calcule la moyenne de la valeur demandée.

ORDER BY + limit = classe et affiche uniquement les 10 premières valeurs de l'attribut demandé.

Résultats

= prix moyen de la cotisation mensuelle de tout les contrats possédés par l'entreprise (1),
puis pour les 10 départements les plus chers, ordonnés de façon décroissante (2),
et nombre de contrats possédés par l'entreprise en fonction de la valeur déclarée pour les biens du logement (3).

Analyse

⇒ Prix moyen de la cotisation mensuelle plus élevé que la moyenne nationale : 17,20 € (*source lesfurets.com*).

⇒ Seuls 3 départements la dépassent, situés dans la région Ile-de-France.
+ Paris = département le plus cher avec 36,40 € de moyenne.

- Majorité des contrats souscrits associés à une valeur déclarée de biens présents dans le logement < 25 000 €.
- Catégorie entre 25 000 et 50 000 € bien représentée également.
- Catégories de valeur > 50 000 € très peu représentées.

Valeur declaree biens	Nombre de contrat:
0-25000	22720
100000+	104
25000-50000	6815
50000-100000	696

Nombre de contrats souscrits par catégorie de valeur déclarée pour les biens présents dans le logement.

dep nom	Prix moyen cotisation mensuelle
Paris	36.4
Hauts-de-Seine	26.27
Val-de-Marne	19.82
Yvelines	18.89
Rhône	18.49
Ain	18.24
Alpes-Maritimes	18.14
Charente-Maritime	17.32
Haute-Savoie	17.15
Corse-du-Sud	17.07

Liste des 10 départements dont le prix moyen de la cotisation mensuelle est le plus élevé.

Conclusion

11

Analyser et comparer les données

-> Ile-de-France et Auvergne-Rhône-Alpes =

- régions les plus peuplées et ayant le plus de contrats d'assurance
- prix moyens d'assurance habitation les plus élevés de France (*source lelynx.fr*).

-> Nouvelle-Aquitaine et Occitanie =

- régions suivantes les plus peuplées et ayant l'un des plus grand nombre de contrats d'assurance
- prix moyens d'assurance habitation les moins chers de France (*source lelynx.fr*).

Trouver des axes d'amélioration

-> Adapter les formules proposées aux clients en fonction de :

- la région dans laquelle se situe le logement
- son ancienneté
- le pouvoir d'achat des habitants de la région.

Exemple :

possibilité d'inclure l'assurance des biens contenus dans le logement à hauteur de 50 000 € dans les formules, en restant à un prix moyen de cotisation mensuelle autour de 18 € => augmentation de 1 € mensuel seulement.

Améliorer la base de données

-> Ajouter l'ancienneté du logement (construction, dernière rénovation)
= prendre en compte l'état de vétusté et adapter l'assurance en conséquences.

-> Ajouter le statut de l'occupant (étudiant, salarié, sans emploi...)
= prendre en compte sa capacité de paiement et ajouter un garant si besoin.

-> Ajouter une précision sur la localisation du logement (zone inondable, sismique...)
= adapter la formule à un risque de catastrophe naturelle si nécessaire.